


1. Binary Classification

一个典型的二分类问题，识别图像内容是否是一只猫：



符号说明：

1. 一个样本记为： $(x^{(i)}, y^{(i)})$ ，其中 $x^{(i)} \in \mathbb{R}^n$ ， $y \in \{0, 1\}$
2. m 个样本： $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$
3. 所有样本的输入记为 X ：

$$X = [x^{(1)} \quad x^{(2)} \quad \dots \quad x^{(m)}]$$

$X \in \mathbb{R}^{n \times m}$ ，和很多表达不一样，但只要在推导过程中前后统一就行。

4. 所有样本的输出记为 Y ：

$$Y = [y^{(1)}, y^{(2)}, \dots, y^{(m)}]$$

$$Y \in \mathbb{R}^{1 \times m}.$$

2. Logistic Regression

LR是一种用于二分类的算法，同时也可以将它看做是最小的神经单元。

2.1 Sigmoid函数及性质


$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (1)$$

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)) \quad (2)$$

$$\sigma(-z) = 1 - \sigma(z) \quad (3)$$

$$[\log \sigma(x)]' = 1 - \sigma(x) \quad (4)$$

$$[\log(1 - \sigma(x))] = -\sigma(x) \quad (5)$$



2.2 LR and Cost Function

参数: $w \in \mathbb{R}^{n \times 1}, b \in \mathbb{R}$

输入: $x^{(i)}$

输出: $\hat{y} = \sigma(w^T x^{(i)} + b)$

损失函数:

$$\begin{aligned} J(w, b) &= \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) \\ &= -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right] \end{aligned}$$

损失函数理解:

- 如果 $y^{(i)} = 1$: $\mathcal{L}(\hat{y}^{(i)}, y^{(i)}) = -\log \hat{y}^{(i)}$, 此时 $\hat{y}^{(i)}$ 应接近 1;
- 如果 $y^{(i)} = 0$: $\mathcal{L}(\hat{y}^{(i)}, y^{(i)}) = -\log(1 - \hat{y}^{(i)})$, 此时 $\hat{y}^{(i)}$ 应接近 0;

2.3 GD

符号定义:

$$\begin{aligned} dw &= \frac{\partial J(w, b)}{\partial w} \\ db &= \frac{\partial J(w, b)}{\partial b} \end{aligned}$$

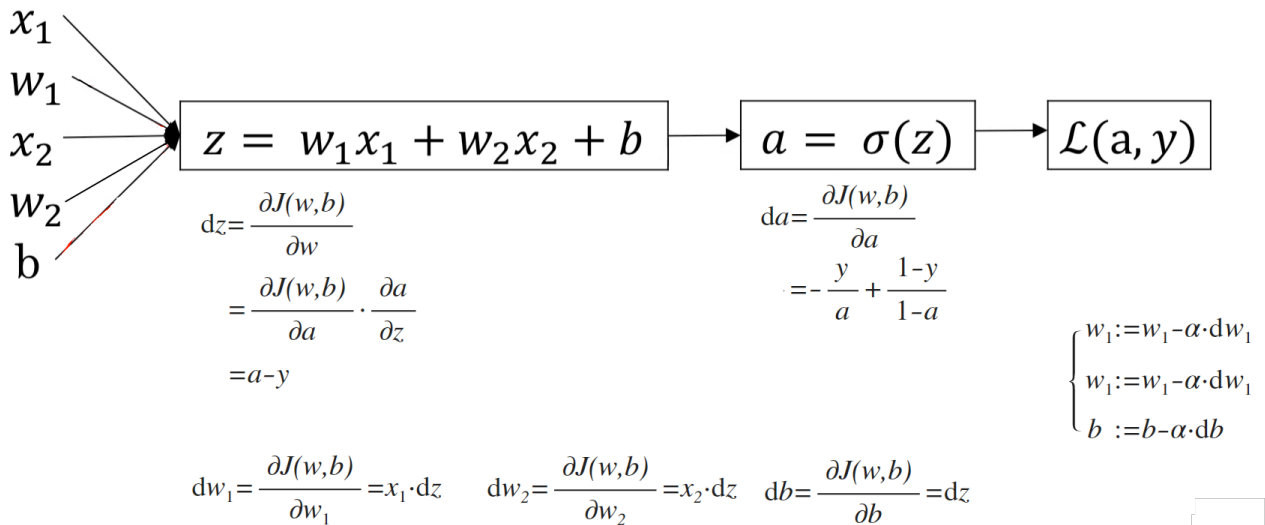
利用梯度下降更新参数时, 设学习率(learning rate)为 α .

则参数更新公式为:

$$\begin{aligned} w &:= w - \alpha \cdot dw \\ b &:= b - \alpha \cdot db \end{aligned}$$

2.4 Computation Graph

计算题示例：



2.5 LR on m examples

m 个样本的训练过程：

$J=0$; $dw_1=0$; $dw_2=0$; $db=0$

for iter=1 to iter_num: loop1

for i=1 to m: loop2

$$z^{(i)} = w^T x^{(i)} + b$$

$$a^{(i)} = \sigma(z^{(i)})$$

$$J += -[y^{(i)} \log a^{(i)} + (1-y^{(i)}) \log (1-a^{(i)})]$$

$$dz^{(i)} = a^{(i)} - y^{(i)}$$

$$dw_1 += x_1^{(i)} \cdot dz^{(i)}$$

$$dw_2 += x_2^{(i)} \cdot dz^{(i)}$$

$$db += dz^{(i)}$$

$J /= m$

$dw_1 /= m$; $dw_2 /= m$; $db /= m$

$$w_1 := w_1 - \alpha \cdot dw_1$$

$$w_2 := w_2 - \alpha \cdot dw_2$$

$$b := b - \alpha \cdot db$$

缺点：抛开最外层的迭代，里面也有两层循环，使用for循环处理，效率太低！

2.6 Vectorization

一种好的解决办法是将for循环改写成向量运算。

使用numpy计算向量内积时的小细节：

```
import numpy as np

X = np.array([[1, 2, 3]])
Y = np.array([[0, 1, 0]])

# 方式一
ret1 = np.dot(X, Y.T)

# 方式二
ret2 = np.sum(X * Y)
print(ret1)
print(ret2)
```

输出：

```
[[2]]
2
```

用向量/矩阵运算代替for循环：

for iter=1 to iter_num:

$$Z = w^T X + b$$

$$A = \sigma(Z)$$

$$dZ = A - Y$$

$$dw = \frac{1}{m} X dZ^T$$

$$db = \frac{1}{m} np.sum(dZ)$$

$$w := w - \alpha \cdot dw$$

$$b := b - \alpha \cdot db$$

3. 问题

3.1 LR的损失函数为什么用交叉熵而不是平方损失？

若用均方差误差来表示LR的损失，则 $\mathcal{L}(w, b)$ 记作：

$$z = w^T x + b \quad (1)$$

$$\hat{y} = \sigma(z) \quad (2)$$

$$\mathcal{L}(w, b) = \frac{1}{2}(\hat{y} - y)^2 \quad (3)$$

则对 w 和 b 的偏导数记作：

$$\frac{\partial \mathcal{L}(w, b)}{\partial w} = (\hat{y} - y)\sigma'(z)x \quad (4)$$

$$\frac{\partial \mathcal{L}(w, b)}{\partial b} = (\hat{y} - y)\sigma'(z) \quad (5)$$

可以看到 w, b 的更新速率与当前的预测值sigmoid函数的导数有关，由sigmoid函数图形可知，当预测值接近0或1时， $\sigma'(z) \approx 0$ ，用梯度下降时，参数更新很慢！

而如果用交叉熵损失，

$$z = w^T x + b \quad (1)$$

$$\hat{y} = \sigma(z) \quad (2)$$

$$\mathcal{L}(w, b) = -\frac{1}{m} \sum y \log \hat{y} + (1 - y) \log(1 - \hat{y}) \quad (3)$$

对 w 求偏导：

$$\frac{\partial \mathcal{L}(w, b)}{\partial w} = \frac{1}{m} \sum x (\sigma(z) - y)$$

可以看到，没有收到 σ 导数的影响。