

本文整理自李建平[机器学习中的矩阵向量求导](#)系列和长躯鬼侠的[矩阵求导术](#)。

1. 符号说明

默认符号：

- x ：标量
- \mathbf{x} ： n 维列向量
- \mathbf{y} ： m 维列向量
- \mathbf{X} ： $m \times n$ 矩阵
- \mathbf{Y} ： $p \times q$ 矩阵

2. 矩阵向量求导布局

自变量\因变量	标量 y	向量 \mathbf{y}	矩阵 \mathbf{Y}
标量 x	/	$\frac{\partial y}{\partial \mathbf{x}}$ 分子布局： m 维列向量（默认） 分母布局： m 维行向量	$\frac{\partial \mathbf{Y}}{\partial x}$ 分子布局： $p \times q$ 矩阵（默认） 分母布局： $q \times p$ 矩阵
向量 \mathbf{x}	$\frac{\partial y}{\partial \mathbf{x}}$ 分子布局： n 维行向量 分母布局： n 维列向量（默认）	$\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ 分子布局： $m \times n$ 雅克比矩阵（默认） 分母布局： $n \times m$ 梯度矩阵	/
矩阵 \mathbf{X}	$\frac{\partial y}{\partial \mathbf{X}}$ 分子布局： $n \times m$ 矩阵 分母布局： $m \times n$ 矩阵（默认）	/	$\frac{\partial \mathbf{Y}}{\partial \mathbf{X}}$ 分母布局： $mn \times pq$ 矩阵

3. 矩阵向量求导大全

自变量\因变量	标量 y	向量 \mathbf{y}	矩阵 \mathbf{Y}
标量 x	$\frac{\partial y}{\partial x}$ 大学微积分知识	$\frac{\partial \mathbf{y}}{\partial x}$ 定义法求导	$\frac{\partial \mathbf{Y}}{\partial x}$ 定义法求导
向量 \mathbf{x}	$\frac{\partial y}{\partial \mathbf{x}}$ 1. 定义法求导 2. 基本法则：线性法则、乘法法则、除法法则 3. 矩阵微分： $df = \text{tr} \left(\left(\frac{\partial f}{\partial \mathbf{x}} \right)^T d\mathbf{x} \right)$ 4. 链式法则： $\frac{\partial z}{\partial \mathbf{x}} = \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)^T \frac{\partial z}{\partial \mathbf{y}}$	$\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ 1. 定义法求导 2. 链式法则： $\frac{\partial \mathbf{z}}{\partial \mathbf{x}} = \frac{\partial \mathbf{z}}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{x}}$	---
矩阵 \mathbf{X}	$\frac{\partial y}{\partial \mathbf{X}}$ 1. 定义法求导 2. 矩阵微分： $df = \text{tr} \left(\left(\frac{\partial f}{\partial \mathbf{X}} \right)^T d\mathbf{X} \right)$ 3. 矩阵微分性质 4. 迹技巧 5. 链式求导法则： $\frac{\partial z}{\partial x_{ij}} = \sum_{k,l} \frac{\partial z}{\partial \mathbf{y}_{kl}} \frac{\partial \mathbf{y}_{kl}}{\partial x_{ij}} = \text{tr} \left(\left(\frac{\partial z}{\partial \mathbf{Y}} \right)^T \frac{\partial \mathbf{Y}}{\partial \mathbf{X}_{ij}} \right)$	---	$\frac{\partial \mathbf{Y}}{\partial \mathbf{X}}$ 1. 定义： $\frac{\partial \mathbf{Y}}{\partial \mathbf{X}} = \frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})}$ 2. 微分法： $\text{vec}(d\mathbf{Y}) = \frac{\partial \mathbf{Y}}{\partial \mathbf{X}}^T \text{vec}(d\mathbf{X})$ 3. 运算法则

4. 标量对向量求导

已知：

$$y = f(\mathbf{x})$$

求：

$$\frac{\partial y}{\partial \mathbf{x}} = ?$$

4.1 定义法求导

所谓标量对向量的求导，其实就是标量对向量里的每个分量分别求导，最后把求导的结果排列在一起，按一个向量表示而已。那么我们可以将实值函数对向量的每一个分量来求导，最后找到规律，得到求导的结果向量。

例1： $y = \mathbf{a}^T \mathbf{x}$

$$\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial x_i} = \frac{\partial \sum_{j=1}^n a_j x_j}{\partial x_i} = \frac{\partial a_i x_i}{\partial x_i} = a_i$$

所以，将求导结果组成向量：

$$\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$$

4.2 标量对向量求导基本法则

在我们寻找一些简单的方法前，我们简单看下标量对向量求导的一些基本法则，这些法则和标量对标量求导的过程类似。

1) 常量对向量的求导结果为0。

2) 线性法则：如果 f, g 都是实值函数， c_1, c_2 为常数，则：

$$\frac{\partial(c_1 f(\mathbf{x}) + c_2 g(\mathbf{x}))}{\partial \mathbf{x}} = c_1 \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} + c_2 \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}}$$

3) 乘法法则：如果 f, g 都是实值函数，则：

$$\frac{\partial f(\mathbf{x})g(\mathbf{x})}{\partial \mathbf{x}} = f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} + \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} g(\mathbf{x})$$

要注意的是如果不是实值函数，则不能这么使用乘法法则。

4) 除法法则：如果 f, g 都是实值函数，且 $g(\mathbf{x}) \neq 0$ ，则：

$$\frac{\partial f(\mathbf{x})/g(\mathbf{x})}{\partial \mathbf{x}} = \frac{1}{g^2(\mathbf{x})} (g(\mathbf{x}) \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} - f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}})$$

4.3 通过向量微分求导

利用导数和微分之间的关系：

$$df = \sum_{i=1}^n \frac{\partial f}{\partial x_i} dx_i = \left(\frac{\partial f}{\partial \mathbf{x}} \right)^T d\mathbf{x}$$

例： $y = \mathbf{x}^T \mathbf{x}$

$$\begin{aligned} dy &= d(\mathbf{x}^T) \mathbf{x} + \mathbf{x}^T d\mathbf{x} \\ &= (d\mathbf{x})^T \mathbf{x} + \mathbf{x}^T d\mathbf{x} \\ &= \mathbf{x}^T d\mathbf{x} + \mathbf{x}^T d\mathbf{x} \\ &= 2\mathbf{x}^T d\mathbf{x} \end{aligned}$$

所以，根据导数与微分的联系：

$$\frac{\partial \mathbf{x}^T \mathbf{x}}{\partial \mathbf{x}} = 2\mathbf{x}$$

4.4 标量对多个向量的链式求导法则

若标量 z 和向量 \mathbf{x}, \mathbf{y} 之间的依赖关系为： $\mathbf{x} \rightarrow \mathbf{y} \rightarrow z$ ，则：

$$\frac{\partial z}{\partial \mathbf{x}} = \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)^T \frac{\partial z}{\partial \mathbf{y}}$$

推广到多个向量的情况， $\mathbf{y}_1 \rightarrow \mathbf{y}_2 \rightarrow \cdots \rightarrow \mathbf{y}_n \rightarrow z$ ，则有：

$$\frac{\partial z}{\partial \mathbf{y}_1} = \left(\frac{\partial \mathbf{y}_n}{\partial \mathbf{y}_{n-1}} \frac{\partial \mathbf{y}_{n-1}}{\partial \mathbf{y}_{n-2}} \cdots \frac{\partial \mathbf{y}_2}{\partial \mathbf{y}_1} \right)^T \frac{\partial z}{\partial \mathbf{y}_n}$$

5. 标量对矩阵求导

已知：

$$y = f(X)$$

求：

$$\frac{\partial y}{\partial X} = ?$$

5.1 定义法求导

与标量对向量求导类似，标量对矩阵里的每个分量分别求导，最后把求导的结果排列在一起，用一个矩阵表示而已。

例： $y = \mathbf{a}^T X \mathbf{b}$ ，求 $\frac{\partial y}{\partial X}$

先对矩阵 X 的任意一个位置的 X_{ij} 求导：

$$\frac{\partial \mathbf{a}^T X \mathbf{b}}{\partial X_{ij}} = \frac{\partial \sum_{p=1}^m \sum_{q=1}^n a_p X_{pq} b_q}{\partial X_{ij}} = \frac{\partial a_i X_{ij} b_j}{\partial X_{ij}} = a_i b_j$$

将所有位置求导结果排成 $m \times n$ 矩阵，得：

$$\frac{\partial \mathbf{a}^T X \mathbf{b}}{\partial X} = \mathbf{a} \mathbf{b}^T$$

5.2 通过矩阵微分求导

一元微积分中的导数（标量对标量的导数）与微分之间的关系：

$$df = f'(x)dx$$

多元微积分中的梯度（标量对向量的导数）与微分之间的关系：

$$df = \sum_{i=1}^n \frac{\partial f}{\partial x_i} dx_i = \frac{\partial f}{\partial \mathbf{x}}^T d\mathbf{x}$$

矩阵导数与微分之间的关系：

$$df = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial f}{\partial X_{ij}} dX_{ij} = \text{tr} \left(\frac{\partial f}{\partial X}^T dX \right)$$

利用导数与微分，以及迹技巧，可以求得标量函数 f 对于矩阵 X 的导数：

- 对标量函数 f 求微分，需用到矩阵微分运算法则；
- 使用迹技巧，对 df 套上迹，再将其它项移至 dX 左侧；

- 对照导数与微分之间的联系，可求得 $\frac{\partial f}{\partial X}$

注：标量对矩阵的求导不能随意沿用标量的链式求导法则。

5.3 矩阵微分运算法则

矩阵加减法	法则	示例
矩阵加减法	$d(X \pm Y) = dX \pm dY$	
矩阵乘法	$d(XY) = (dX)Y + X(dY)$	
矩阵转置	$d(X^T) = (dX)^T$	
矩阵的迹	$d\text{tr}(X) = \text{tr}(dX)$	
矩阵的逆	$dX^{-1} = -X^{-1}dXX^{-1}$	
行列式	$d X = \text{tr}(X^\# dX)$	$X^\#$ 是 X 的伴随矩阵
逐元素相乘	$d(X \odot Y) = dX \odot Y + X \odot dY$	
逐元素函数	$d\sigma(X) = \sigma'(X) \odot dX$	$d\sin(X) = \cos(X) \odot dX$

5.4 迹技巧（trace trick）

运算	法则	备注
标量套上迹	$a = \text{tr}(a)$	
转置	$\text{tr}(A^T) = \text{tr}(A)$	
线性	$\text{tr}(A \pm B) = \text{tr}(A) \pm \text{tr}(B)$	
矩阵乘法交换	$\text{tr}(AB) = \text{tr}(BA)$	A 与 B^T 维度相同，两侧都等于 $\sum_{ij} A_{ij}B_{ji}$
矩阵乘法/逐元乘法交换	$\text{tr}(A^T(B \odot C)) = \text{tr}((A \odot B)^T C)$	A, B, C 尺寸相同，两侧都等于 $\sum_{ij} A_{ij}B_{ij}C_{ij}$

5.5 标量对多个矩阵的链式求导法则

假设有这样的依赖关系： $X \rightarrow Y \rightarrow z$ ，很难给出矩阵基于矩阵整体的链式求导法则，可以给出关于 X 中某一标量的链式求导：

$$\frac{\partial z}{\partial X_{ij}} = \sum_{k,l} \frac{\partial z}{\partial Y_{kl}} \frac{\partial Y_{kl}}{\partial X_{ij}} = \text{tr} \left(\left(\frac{\partial z}{\partial \mathbf{Y}} \right)^T \frac{\partial \mathbf{Y}}{\partial \mathbf{X}_{ij}} \right)$$

5.6 计算示例

例1: $f = \mathbf{a}^T X \mathbf{b}$ ，求 $\frac{\partial f}{\partial X}$ 。其中 \mathbf{a} 是 $m \times 1$ 列向量， X 是 $m \times n$ 矩阵， \mathbf{b} 是 $n \times 1$ 列向量。

Step1: 使用矩阵乘法法则求微分：

$$df = d\mathbf{a}^T X \mathbf{b} + \mathbf{a}^T dX \mathbf{b} + \mathbf{a}^T X d\mathbf{b} = \mathbf{a}^T dX \mathbf{b}$$

这里因为 \mathbf{a}, \mathbf{b} 是常量，所以 $d\mathbf{a} = 0, d\mathbf{b} = 0$

Step2: 套上迹，并做矩阵乘法交换：

$$df = \text{tr}(\mathbf{a}^T dX \mathbf{b}) = \text{tr}(\mathbf{b} \mathbf{a}^T dX) = \text{tr}((\mathbf{a} \mathbf{b}^T)^T dX)$$

Step3: 对照导数与微分之间的联系：

$$\frac{\partial f}{\partial X} = \mathbf{a} \mathbf{b}^T$$

例2: $f = \mathbf{a}^T \exp(X \mathbf{b})$ ，求 $\frac{\partial f}{\partial X}$ 。

Step1: 使用矩阵乘法法则求微分：

$$df = \mathbf{a}^T (\exp(X \mathbf{b}) \odot (dX \mathbf{b}))$$

Step2: 套上迹，并做矩阵乘法交换：

$$\begin{aligned} df &= \text{tr}(\mathbf{a}^T (\exp(X \mathbf{b}) \odot (dX \mathbf{b}))) \\ &= \text{tr}((\mathbf{a} \odot \exp(X \mathbf{b}))^T dX \mathbf{b}) \\ &= \text{tr}(\mathbf{b} (\mathbf{a} \odot \exp(X \mathbf{b}))^T dX) \\ &= \text{tr}(((\mathbf{a} \odot \exp(X \mathbf{b})) \mathbf{b}^T)^T dX) \end{aligned}$$

Step3: 对照导数与微分之间的联系：

$$\frac{\partial f}{\partial X} = (\mathbf{a} \odot \exp(X \mathbf{b})) \mathbf{b}^T$$

例3 【线性回归】 $l = \|X \mathbf{w} - \mathbf{y}\|^2$ ，求 \mathbf{w} 的最小二乘估计。其中 \mathbf{y} 是 $m \times 1$ 列向量， X 是 $m \times n$ 矩阵， \mathbf{w} 是 $n \times 1$ 列向量， l 是标量。

Step1: 将向量模平方改成向量与内积形式：

$$l = (X \mathbf{w} - \mathbf{y})^T (X \mathbf{w} - \mathbf{y})$$

Step1: 使用矩阵乘法法则求微分:

$$\begin{aligned} dl &= (Xd\mathbf{w})^T (X\mathbf{w} - \mathbf{y}) + (X\mathbf{w} - \mathbf{y})^T (Xd\mathbf{w}) \\ &= 2(X\mathbf{w} - \mathbf{y})^T (Xd\mathbf{w}) \end{aligned}$$

$\because Xd\mathbf{w}$ $X\mathbf{w} - \mathbf{y}$ are coloum vector

$$\therefore (Xd\mathbf{w})^T (X\mathbf{w} - \mathbf{y}) = (X\mathbf{w} - \mathbf{y})^T (Xd\mathbf{w})$$

Step2: 套上迹, 并做矩阵乘法交换:

$$dl = \text{tr} \left((2X^T (X\mathbf{w} - \mathbf{y}))^T d\mathbf{w} \right)$$

Step3: 对照导数与微分之间的联系:

$$\frac{\partial l}{\partial \mathbf{w}} = 2X^T (X\mathbf{w} - \mathbf{y})$$

Step3: 求 \mathbf{w} 的最小二乘估计

$$\begin{aligned} \frac{\partial l}{\partial \mathbf{w}} &= 2X^T (X\mathbf{w} - \mathbf{y}) = 0 \\ \mathbf{w} &= (X^T X)^{-1} X^T \mathbf{y} \end{aligned}$$

6. 向量对向量求导

向量对向量的求导比较麻烦, m 为列向量 \mathbf{y} 对 n 维列向量 \mathbf{x} 求导, 那么一共有 mn 个标量对标量的求导。

分子布局 (numerator layout) :

求导结果矩阵的第一个维度以分子为准, 结果是一个 $m \times n$ 矩阵, 一般叫作雅克比矩阵。

分母布局 (denominator layout) :

求导结果矩阵的第一个维度以分母为准, 结果是一个 $n \times m$ 矩阵, 一般叫作梯度矩阵。

对于机器学习算法原理中的推导, 究竟是采用什么布局一般是隐含的, 需自己推导。本文以分子布局的雅克比矩阵为主。

6.1 定义法求导

例: $\mathbf{y} = A\mathbf{x}$, 其中 A 是 $n \times m$ 的矩阵, \mathbf{x}, \mathbf{y} 分别是 m, n 维列向量。

Step1: 先求 \mathbf{y} 的第 i 个分量对 \mathbf{x} 的第 j 个分量的导数:

$$\frac{\partial A_i \mathbf{x}}{\partial \mathbf{x}_j} = \frac{\partial A_{ij} x_j}{\partial \mathbf{x}_j} = A_{ij}$$

Step2: 将每个标量求导结果排列成矩阵，这里用分子布局：

$$\frac{\partial A \mathbf{x}}{\partial \mathbf{x}_j} = A$$

6.2 向量对向量求导的链式法则

若向量之间有这样的依赖关系： $\mathbf{x} \rightarrow \mathbf{y} \rightarrow \mathbf{z}$ ，则有下面的链式求导法则：

$$\frac{\partial \mathbf{z}}{\partial \mathbf{x}} = \frac{\partial \mathbf{z}}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{x}}$$

7. 矩阵对矩阵求导

7.1 矩阵对矩阵求导定义

$\frac{\partial F}{\partial X}$ ， $F: p \times q$ ， $X: m \times n$ 矩阵 F 中的 pq 个元素要分别对矩阵 X 中的 mn 个元素求导，那么求导结果一共有 $mnpq$ 个元素。求导结果的排列有很多种。这里只介绍目前主流的做法。

目前主流的矩阵对矩阵求导定义是对矩阵先做向量化，然后再使用向量对向量的求导。而这里的向量化一般是使用列向量化。也就是说，现在我们的矩阵对矩阵求导可以表示为：

$$\frac{\partial F}{\partial X} = \frac{\partial \text{vec}(F)}{\partial \text{vec}(X)}$$

$\text{vec}(F)$ 的维度是 $pq \times 1$ 列向量， $\text{vec}(X)$ 的维度是 $mn \times 1$ 列向量。结果使用分母布局，得到一个 $mn \times pq$ 的矩阵。

7.2 微分求导法

利用导数与微分的联系：

$$\text{vec}(dF) = \frac{\partial F^T}{\partial X} \text{vec}(dX)$$

求解步骤：

1. 使用矩阵微分运算法则对矩阵 F 求微分；
2. 做向量化并使用迹技巧将其它项交换至 $\text{vec}(dX)$ 的左侧；
3. 根据导数与微分关系，得到矩阵对矩阵的微分结果。

7.3 矩阵向量化的运算法则

性质	法则
线性性质	$\text{vec}(A + B) = \text{vec}(A) + \text{vec}(B)$
矩阵乘法	$\text{vec}(AXB) = (B^T \otimes A) \text{vec}(X)$
矩阵转置	$\text{vec}(A^T) = K_{mn} \text{vec}(A)$
逐元素乘法	$\text{vec}(A \odot X) = \text{diag}(\text{vec}(A)) \text{vec}(X)$

注：

1. \otimes ：克罗内克(Kronecker)积， $A(m \times n)$ 与 $B(p \times q)$ 的克罗内克积是 $A \otimes B = [A_{ij} B](mp \times nq)$ ；
2. K_{mn} ：交换矩阵。若 $\text{vec}(A)$ 是 $mn \times 1$ 的列向量，则 $K_{mn}(mn \times mn)$ ，将按列优先的向量化变为按行优先的向量化；
3. $\text{diag}(A)(mn \times mn)$ 是用 A 的元素（列优先）排成的对角阵。

7.4 克罗内克积运算法则

1. $(A \otimes B)^T = A^T \otimes B^T$
2. $\text{vec}(\mathbf{a}\mathbf{b}^T) = \mathbf{b} \otimes \mathbf{a}$
3. $(A \otimes B)(C \otimes D) = AC \otimes BD$
4. $K_{mn} = K_{nm}^T, \quad K_{mn} K_{nm} = I$

7.5 计算实例

参见[矩阵求导术（下）](#)

参考

1. [机器学习中的矩阵向量求导\(一\) 求导定义与求导布局](#)
2. [机器学习中的矩阵向量求导\(二\) 矩阵向量求导之定义法](#)
3. [机器学习中的矩阵向量求导\(三\) 矩阵向量求导之微分法](#)
4. [机器学习中的矩阵向量求导\(四\) 矩阵向量求导链式法则](#)
5. [机器学习中的矩阵向量求导\(五\) 矩阵对矩阵的求导](#)
6. [矩阵求导术（上）](#)
7. [矩阵求导术（下）](#)